



UNIVERSIDADE FEDERAL DO CEARÁ

DEPARTAMENTO DE COMPUTAÇÃO
Prof. Dr. José Antônio Fernandes de Macêdo

TRABALHO PRÁTICO #01

Mineração de Dados

Relatório de *Data Profiling* em 5 *Datasets* do `scikit-learn`

ALUNOS

Francisco Irlisson Ferreira Dias	581523
Larissa Vitória Santos Menezes	553875
Maria Cecília Alves Castro	553577

Gerador de <i>Profiling</i>	ydata-profiling 4.18.4
Fonte dos Dados	scikit-learn 1.6.1
Manipulação dos Dados	pandas 2.2.3

06 de agosto de 2026

Sumário

1	Objetivo	1
2	Ficha técnica dos 5 <i>datasets</i>	1
3	Achados	2
3.1	Iris	2
3.2	Wine	2
3.3	Breast Cancer	2
3.4	Diabetes	3
3.5	California Houses	3
4	Análise Cruzada	4
5	Recomendações	5
6	Limites do <i>Profiling</i> Automático	6

1 Objetivo

Este relatório apresenta a aplicação da biblioteca *ydata-profiling* a cinco conjuntos de dados clássicos do *scikit-learn*, *Iris*, *Wine*, *Breast Cancer*, *Diabetes* e *California Housing*, com o propósito de transformar as estatísticas geradas automaticamente em decisões concretas de análise. Mais do que descrever cada *dataset*, buscamos interpretar os relatórios a partir de um roteiro fixo de seis etapas: contexto, estrutura, qualidade, distribuições, relações e decisão. Essa abordagem evita que o *profiling* seja tratado como um fim em si mesmo, reforçando que a ferramenta serve para orientar escolhas de pré-processamento e modelagem, e não para substituí-las.

2 Ficha técnica dos 5 *datasets*

Dataset	Linhas	Colunas	Tipos	Num.	Cat.	% Ausentes	% Zeros	Duplicatas
<i>Iris</i>	150	5	float64 (4), int64 (1)	5	0	0	6,67	1
<i>Wine</i>	178	14	float64 (13), int64 (1)	13	1	0	2,37	0
<i>Breast Cancer</i>	569	31	float64 (30), int64 (1)	30	1	0	1,64	0
<i>Diabetes</i>	442	11	float64 (10), int64 (1)	10	1	0	0	0
<i>California Houses</i>	20.640	9	float64 (9)	9	0	0	0	0

De modo geral, os cinco conjuntos são *datasets* didáticos já curados pelo *scikit-learn*, o que explica a ausência de valores faltantes em todos eles, um cenário pouco realista fora de contexto acadêmico, mas que permite concentrar a análise em outros aspectos de qualidade, como duplicatas, redundância entre atributos e discrepâncias entre o tipo inferido e o tipo semântico de cada variável.

3 Achados

■ 3.1 Iris

O relatório gerado para o *Iris* confirma sua reputação de dataset “bem comportado”, mas ainda assim revela três pontos importantes. Em primeiro lugar, o *profiling* aponta a existência de uma duplicata exata. As linhas 101 e 142 apresentam valores idênticos para as quatro medidas (*sepal length* de 5,8 cm, *sepal width* de 2,7 cm, *petal length* de 5,1 cm e *petal width* de 1,9 cm), ambas pertencentes à classe *virginica*. Como isso corresponde a apenas 0,67% das 150 observações, é mais plausível que se trate de uma coincidência de medição entre flores semelhantes do que de um erro de coleta. Ainda assim, a duplicata deve ser tratada antes da divisão entre treino e teste para evitar que a mesma amostra apareça nos dois conjuntos e infle artificialmente o desempenho do modelo. Em segundo lugar, o dicionário de dados (*DESCR*) confirma o balanceamento perfeito das três classes, com 50 observações cada, não havendo necessidade de técnicas de balanceamento, como ponderação de classes, e métricas simples, como a acurácia, já são suficientes para avaliar o desempenho de um classificador de forma confiável. Por fim, há assimetria no poder discriminativo dos atributos. Segundo as correlações reportadas no *DESCR*, *petal length* e *petal width* apresentam correlação de 0,9490 e 0,9565 com a classe, respectivamente, enquanto *sepal width* apresenta apenas $-0,4194$. Isso sugere que as variáveis relacionadas à pétala concentram a maior parte da informação preditiva, o que deve orientar a interpretação de modelos lineares, nos quais *sepal width* tende a receber peso baixo, e eventuais estratégias de seleção de atributos. Além disso, embora o *target* seja inferido como numérico, codificado como 0, 1 ou 2, semanticamente representa a espécie da flor. Essa discrepância explica o índice enganoso de “6,67% de zeros” na ficha técnica, que não corresponde a medidas físicas nulas, mas às 50 observações da classe 0 (*Setosa*).

■ 3.2 Wine

O relatório gerado para o *Wine* também revela pontos importantes, começando pela questão da escala. As 13 variáveis operam em amplitudes bastante distintas: *hue* varia de 0,48 a 1,71, enquanto *proline* chega a valores entre 278 e 1680, uma diferença de mais de mil vezes na escala bruta (desvio-padrão de 0,23 contra 314,9, respectivamente). Isso significa que qualquer distância euclidiana calculada sobre os dados brutos seria dominada quase inteiramente por *proline*, ofuscando variáveis de menor amplitude mesmo que estas carreguem informação discriminativa relevante. Por isso, a padronização (*StandardScaler*) é etapa obrigatória antes de qualquer método baseado em distância, como *KNN*, *k-means* ou *SVM-RBF*. Em segundo lugar, há uma assimetria clara entre poder discriminativo e redundância entre os atributos fenólicos. *flavanoids* é a variável mais correlacionada com o *target* ($r = -0,85$), seguida de perto por *total_phenols* ($r = -0,72$); porém, essas duas variáveis também são fortemente correlacionadas entre si ($r = 0,865$), o que reflete a composição química do vinho (fenóis totais incluem flavonoides) e não um vazamento de rótulo. Na prática, isso significa alto poder preditivo isolado, mas baixo ganho ao usar as duas simultaneamente, o que as torna candidatas naturais a *PCA* ou seleção de atributos em modelos lineares. Por fim, *magnesium* chama atenção pela distribuição com cauda pesada à direita (assimetria de 1,10, curtose de 2,10), somando quatro *outliers* pelo critério do *IQR*: o limite superior calculado é 135,5, enquanto o valor máximo observado chega a 162. Essa característica favorece transformações como o logaritmo ou o uso de modelos robustos a *outliers*, como árvores de decisão, em vez de abordagens que pressupõem normalidade na distribuição.

■ 3.3 Breast Cancer

O relatório gerado para o *Breast Cancer* trouxe pontos girando em torno de redundância e escala entre as 30 *features*. Em primeiro lugar, as tríades *radius*–*perimeter*–*area* (nas versões *mean*, *SE* e *worst*) são praticamente colineares entre si: *mean radius* correlaciona-se com *mean perimeter*

em 0,998 e com `mean area` em 0,987, padrão que se repete nas versões *SE* e *worst*, totalizando 15 pares com $|r| > 0,95$ no dataset. Manter as três variantes de cada tríade infla a multicolinearidade sem agregar informação nova, o que torna razoável descartar `perimeter` e `area` e ficar apenas com `radius` por grupo, considerando questões de interpretabilidade, ou aplicar *PCA* como alternativa. Em segundo lugar, existe um segundo cluster redundante entre `concavity`, `compactness` e `concave points`, com correlações par a par entre 0,83 e 0,92. O tratamento recomendado é análogo ao da tríade anterior: reduzir para uma *feature* representativa por cluster ou recorrer a regularização L1/L2 em vez de seleção manual, especialmente relevante porque `worst concave points` ($r = 0,79$) e `worst perimeter` ($r = 0,78$) figuram entre as variáveis mais correlacionadas com o diagnóstico, indicando que tamanho e irregularidade de contorno concentram boa parte do sinal preditivo. Por fim, há uma discrepância de escala entre as variáveis, `mean area` varia de 143 a 2501, enquanto `mean smoothness` fica entre 0,05 e 0,16, somada à forte assimetria em colunas `_error`, como `area error` ($\text{skew} = 5,4$) e `concavity error` ($\text{skew} = 5,1$). Essa combinação exige *StandardScaler* para qualquer modelo sensível a escala (regressão logística, SVM, KNN, PCA), enquanto a assimetria nas colunas de erro sugere *log-transform* ou o uso de modelos baseados em árvore, naturalmente invariantes tanto à escala quanto a *outliers*.

■ 3.4 Diabetes

O dataset *Diabetes* contém 442 pacientes e 11 colunas (10 variáveis basais — idade, sexo, IMC, pressão arterial e seis medições séricas — mais o alvo, progressão da doença após um ano), já centralizado e escalonado, sem dados ausentes ou duplicados, com `sex` sendo categórica mas lida como numérica. Nas distribuições, `bp`, `s1`, `s2`, `s5`, `s6` e `target` são aproximadamente simétricas, `bmi`, `s3` e `s4` têm assimetria à direita e `age` à esquerda; `age`, `bp` e `target` são platicúrticas, enquanto as demais são leptocúrticas (mais propensas a *outliers*); `bp` e `s4` mostram sinais visuais de multimodalidade. Pelo critério de Tukey, `age`, `sex`, `bp` e `target` não têm *outliers*, enquanto `s1` e `s6` concentram os mais numerosos (8 e 9, respectivamente), com `s6` sendo a única variável com *outliers* nos dois lados da distribuição. A matriz de correlação revela forte colinearidade no bloco lipídico `s1–s5` (destaque para `s1–s2`, $r = 0,90$, e `s3–s4`, $r = -0,74$), sugerindo redundância que pede atenção via *VIF*, regularização ou *PCA* — mas sem sinal de vazamento do alvo, já que as correlações mais altas com `target` (`bmi` = 0,59 e `s5` = 0,57) são moderadas e biologicamente plausíveis. Em suma, o dataset é limpo e sem problemas graves, mas apresenta multicolinearidade real e indícios de estrutura não linear ou segmentada que devem orientar as escolhas de modelagem.

■ 3.5 California Houses

O dataset *California Housing* (Censo dos EUA de 1990, Pace & Barry 1997) tem cada linha representando um *block group*, com a amostra do relatório cobrindo 5.000 linhas e 9 colunas, todas inferidas corretamente como numéricas (com ressalva para `HouseAge`, que na prática é discreta/ordinal). Está tecnicamente limpo — sem ausentes, duplicatas, colunas constantes ou excesso de zeros — e `Longitude` sendo 100% negativa é esperado pela geografia da Califórnia. Nas distribuições, `AveRooms`, `AveBedrms` e `AveOccup` têm assimetria e curtose extremas com *outliers* graves (por serem razões instáveis em *block groups* com poucos domicílios), enquanto `Latitude` e `Longitude` são claramente bimodais, refletindo os polos urbanos de Los Angeles e São Francisco; já `HouseAge` e o alvo `MedHouseVal` mostram picos artificiais nos valores máximos, evidenciando censura/teto nos dados originais. A correlação mais forte é `Latitude–Longitude` ($r = -0,882$, redundância geográfica), seguida por `MedInc–MedHouseVal` ($r = 0,678$, a relação mais forte com o alvo) e `MedInc–AveRooms` ($r = 0,647$); não há vazamento clássico do alvo, mas a censura do `MedHouseVal` em 5,0 distorce sistematicamente qualquer modelo para valores altos. Isso pede tratamento explícito da censura do alvo, *RobustScaler*/winsorização nas variáveis de razão e engenharia de *features* geográficas em vez do uso bruto de `Latitude/Longitude`.

4 Análise Cruzada

Colocando os cinco relatórios lado a lado, alguns padrões se repetem com frequência suficiente para revelar características recorrentes dos datasets analisados. O primeiro é a ausência quase total de valores faltantes e duplicatas. Nenhum dos cinco conjuntos apresenta dados ausentes, e apenas o *Iris* contém uma duplicata isolada. Esse cenário de qualidade dificilmente se repetiria em dados coletados fora de um contexto acadêmico.

O segundo padrão, mais revelador, está relacionado às limitações do *profiling* automático. Em três dos cinco datasets (*Iris*, *Wine* e *Breast Cancer*), a variável alvo é uma categoria codificada numericamente (0/1/2), mas a ferramenta a trata como numérica contínua. Como consequência, gera o índice enganoso de “% de zeros” na ficha técnica sempre que a classe 0 está presente. O problema, portanto, não é pontual, mas decorre da dificuldade de interpretar corretamente variáveis categóricas codificadas como inteiros.

Outro padrão é a heterogeneidade de escala entre atributos. *Wine* (hue vs. proline), *Breast Cancer* (mean smoothness vs. mean area) e *California Houses* (variáveis Ave* vs. MedInc) apresentam diferenças de até quatro ordens de grandeza. Essa característica exige padronização antes da aplicação de métodos sensíveis à distância. O *Diabetes* é a exceção, por já vir centrado e escalonado pelo próprio *scikit-learn*.

A redundância entre atributos também aparece em diferentes cenários. No *Breast Cancer*, há 15 pares com $|r| > 0,95$ nas tríades radius, perimeter e area. No *Diabetes*, observa-se um bloco colinear entre s1 e s6. Já no *California Houses*, Latitude e Longitude apresentam forte correlação ($r = -0,882$). Esse padrão sugere que a multicolinearidade está mais relacionada ao processo de geração dos dados, com medidas derivadas umas das outras, do que a uma falha isolada de um conjunto específico. Em nenhum dos cinco datasets, porém, foi identificado vazamento clássico do alvo. As correlações mais altas com a variável alvo são explicáveis pelo domínio. Ainda assim, *Breast Cancer* e *California Houses* apresentam problemas estruturais com riscos equivalentes para a modelagem. No primeiro, a redundância entre preditores pode comprometer a interpretação dos modelos. No segundo, a censura do alvo exige cautela na interpretação dos resultados.

Em termos de esforço de pré-processamento, os cinco datasets não são equivalentes. *California Houses* e *Breast Cancer* se destacam como os que mais exigem preparação, ainda que por motivos distintos. No primeiro, a combinação de *outliers* extremos, censura no teto do alvo e redundância geográfica torna o tratamento mais complexo. Entre os *outliers*, destaca-se AveRooms, que chega a 132,5 contra um limite de Tukey de 8,48. Esse cenário exige atenção à escala, ao tratamento de valores extremos e à possível engenharia de *features*. No *Breast Cancer*, o principal desafio é a combinação entre alta dimensionalidade, com 30 variáveis, e redundância estrutural. Essa característica justifica a consideração de seleção de atributos ou redução de dimensionalidade antes da modelagem. *Wine* ocupa uma posição intermediária. Embora exija padronização de escala e atenção ao desbalanceamento moderado das classes, não apresenta o mesmo nível de redundância dos dois primeiros. *Diabetes* exige menos preparação do que se imaginaria à primeira vista. Como a escala já foi resolvida, o maior cuidado está na multicolinearidade entre o bloco lipídico (s1 a s6) e na recodificação da variável sex. *Iris*, por fim, é o dataset que exige menor esforço de preparação, pois, além do tratamento pontual da duplicata, está praticamente pronto para uso, com classes balanceadas e baixa dissimilaridade de escala entre os atributos.

5 Recomendações

■ Iris

Antes da divisão entre treino e teste, verificar a duplicata existente, evitando que a mesma amostra apareça em conjuntos diferentes. Em seguida, pode-se aplicar uma técnica de padronização aos quatro atributos, como o *StandardScaler*, que coloca as variáveis em uma escala comparável. Isso, embora não seja estritamente necessário, pode favorecer modelos sensíveis à escala, como *KNN* e *SVM*.

■ Wine

Padronizar todas as variáveis com o *StandardScaler*, já que há diferença de escala muito grande entre elas (proline chega a milhares, hue fica abaixo de 2). Tratar a redundância entre flavanoids e total_phenols ($r = 0,865$), escolhendo manter apenas uma delas ou aplicando *PCA*. Usar divisão treino/teste estratificada por causa do leve desbalanceamento entre classes (33%/40%/27%). Modelos baseados em árvore, entretanto, dispensam esse pré-processamento.

■ Breast Cancer

Padronizar todas as 30 *features*, já que há grande diferença de escala entre elas (area chega a milhares, smoothness fica abaixo de 1). Reduzir a redundância das tríades radius/perimeter/area e do cluster compactness/concavity/concave points, via remoção manual ou *PCA*. Usar validação estratificada e métricas como *F1-score* ou *AUC*, já que as classes são moderadamente desbalanceadas (63%/37%). Modelos baseados em árvore (*Random Forest*, *Gradient Boosting*) toleram bem a colinearidade e a assimetria sem precisar desse pré-processamento.

■ Diabetes

A principal recomendação é lidar com a multicolinearidade real existente no bloco lipídico s1–s5 (especialmente s1 e s2, $r = 0,90$, e s3 ↔ s4, $r = -0,74$), o ideal é calcular o *VIF* dessas variáveis e, dependendo do objetivo, remover uma de cada par redundante, aplicar *PCA* no bloco lipídico, ou preferir regularização (*Ridge/Elastic Net*) em vez de regressão linear pura (*OLS*), já que ela é naturalmente instável nesse cenário. Como os *outliers* são leves (no máximo 2% das observações, quase todos na cauda superior) e o target não tem *outliers* nem sinal de vazamento, não há necessidade de tratamento agressivo, assim, usar *RobustScaler* já é suficiente para dar conta das caudas sem distorcer o modelo. Dado que N é pequeno (442 observações), qualquer avaliação de modelo deve usar validação cruzada, e a leve multimodalidade em bp e s4 sugere que modelos baseados em árvore (*Random Forest*, *Gradient Boosting*) podem capturar melhor eventuais subgrupos de pacientes do que um modelo estritamente linear.

■ California Houses

A recomendação mais urgente é tratar a censura do alvo MedHouseVal em 5,0, seja removendo as observações no teto, seja tratando o problema como regressão censurada, seja ao menos documentando que o modelo vai subestimar sistematicamente imóveis de alto valor. Em seguida, é essencial usar *RobustScaler* (ou *winsorizar* nos percentis 1%/99%) nas variáveis AveRooms, AveBedrms e AveOccup, cujos *outliers* extremos vêm de razões instáveis em *block groups* com poucos domicílios, e não devem ser tratados como erros a remover, mas como uma fonte real de ruído a mitigar na escala. Latitude e Longitude não devem ser usadas cruas em modelos lineares por serem redundantes entre si ($r = -0,882$) e multimodais, o ideal é engenharia de *features* geográficas (distância a polos urbanos, clusterização) ou, mais simplesmente, optar por um modelo baseado em árvore (*Random Forest*, *Gradient Boosting*), que captura essas interações espaciais e lida naturalmente com os *outliers* e a colinearidade sem exigir pré-processamento tão elaborado.

6 Limites do *Profiling* Automático

Embora o *ydata-profiling* calcule um volume expressivo de estatísticas relevantes, como distribuições, correlações, duplicatas e valores ausentes, seus resultados permanecem condicionados às características observáveis dos dados e à inferência automática de seus tipos.

A ferramenta não possui, por si só, conhecimento sobre o problema de negócio ou sobre o significado das variáveis no domínio em que os dados foram produzidos. Essa limitação se manifesta de diferentes formas ao longo da análise. Uma delas é a impossibilidade de distinguir, apenas com base em critérios estatísticos, um valor extremo legítimo de um erro de medição. O *profiling* pode identificar um possível *outlier*, mas cabe ao analista verificar se ele representa um fenômeno válido ou uma falha na coleta. Outra limitação está na interpretação semântica das variáveis. No dataset *Iris*, por exemplo, uma variável-alvo codificada numericamente pode ser identificada como numérica, embora represente categorias. Nesse caso, as estatísticas calculadas podem estar matematicamente corretas, mas sua interpretação como medidas de uma variável contínua seria inadequada. Da mesma forma, o *profiling* não é capaz de validar regras de negócio que dependam de conhecimento externo aos dados, como identificar que uma data de saída anterior à data de entrada constitui uma inconsistência. Por fim, uma correlação elevada entre um atributo e a variável-alvo não permite, por si só, concluir que esse atributo seja um bom preditor, pois a relação pode refletir redundância, dependência estrutural ou até vazamento de dados. Novamente, cabe ao analista interpretar esses resultados e decidir quais ações são adequadas ao problema.

Assim, o *profiling* automático deve ser entendido como um ponto de partida para a investigação dos dados. Em geral, ele amplia e sistematiza a etapa exploratória, mas a validação contextual e a transformação das evidências estatísticas em decisões de análise permanecem responsabilidades do analista.